

CRITÉRIO: FATOS INCONTESTÁVEIS

Resumo técnico do modelo Ashg2099/xlm-roberta-factchecker

Aplicação em um sistema de verificação factual de notícias

1. Ferramenta escolhida

Para o critério **Fatos Incontestáveis**, será utilizado o modelo **Ashg2099/xlm-roberta-factchecker**.

O modelo é uma versão do XLM-RoBERTa Base ajustada especificamente para verificação factual de afirmações. A versão atual disponibilizada no Hugging Face é a v2 - Retrieval Augmented, ou seja, o modelo não deve analisar somente uma afirmação isoladamente: ele deve receber uma afirmação acompanhada de uma evidência relacionada.

A tarefa é uma classificação de texto com três classes, implementada com XLMRobertaForSequenceClassification em um problema de classificação de rótulo único.

2. Objetivo no nosso projeto

No nosso projeto, esse modelo será responsável por responder à pergunta: **“As afirmações factuais presentes nesta notícia são sustentadas por evidências?”**

O modelo não recebe uma notícia completa e decide sozinho se toda a notícia é verdadeira ou falsa. O fluxo correto é:

Notícia -> Extração dos fatos -> Busca de evidências -> Verificação de cada fato -> Resultado consolidado

Exemplo: para a notícia “O Brasil possui 26 estados e Brasília é a capital do país”, o sistema separaria duas afirmações verificáveis:

- O Brasil possui 26 estados.
- Brasília é a capital do Brasil.

Cada afirmação seria verificada individualmente. Isso evita classificar uma notícia inteira como falsa quando apenas uma de várias afirmações estiver errada.

3. Entrada do modelo

O modelo precisa de duas informações principais:

- Claim: a afirmação que queremos verificar.
- Evidence: um texto contendo evidência relacionada à afirmação.

O formato de entrada da versão atual é:

[claim] </s></s> [evidence]

Exemplo

Claim:

A Segunda Guerra Mundial terminou em 1945.

Evidence:

World War II ended in 1945 following the surrender of Germany and subsequently Japan.

Entrada formada:

A Segunda Guerra Mundial terminou em 1945.

</s></s>

World War II ended in 1945 following the surrender of Germany and subsequently Japan.

Essa entrada é tokenizada pelo tokenizer do XLM-RoBERTa. A configuração publicada usa comprimento máximo de 256 tokens, truncamento pelo lado direito e estratégia `longest_first`.

4. Saída do modelo

O modelo possui três classes:

ID	Classe	Significado
0	TRUE	A evidência sustenta a afirmação
1	FALSE	A evidência contradiz a afirmação
2	UNCERTAIN	A evidência não é suficiente para confirmar nem negar

Internamente, a rede retorna três logits. Aplicando softmax, eles podem ser transformados em probabilidades relativas entre as três classes.

Exemplo de saída simplificada:

```
{
  "claim": "A Segunda Guerra Mundial terminou em 1945.",
  "classification": "TRUE",
  "confidence": 0.94
}
```

Essa confiança não representa “94% de probabilidade de verdade absoluta”; ela indica a confiança do classificador entre as classes aprendidas.

5. Dataset utilizado

O modelo informa ter sido treinado utilizando o dataset `copenlu/fever_gold_evidence`, derivado do FEVER - Fact Extraction and VERification.

O FEVER original contém 185.445 afirmações construídas a partir de informações da Wikipédia e avaliadas por anotadores humanos em três categorias:

- SUPPORTS
- REFUTES
- NOT ENOUGH INFO

Para SUPPORTS e REFUTES também são registradas sentenças de evidência. O `fever_gold_evidence` prepara esses dados para treinamento de classificação factual e possui arquivos separados de treinamento, validação e teste:

```
train.jsonl
valid.jsonl
test.jsonl
```

No Hugging Face, o conjunto possui aproximadamente 260 mil registros no total, com cerca de 228 mil exemplos de treinamento.

6. Estrutura dos dados de treinamento

Um registro do dataset contém campos como:

```
claim
label
evidence
id
verifiable
original_id
```

Exemplo simplificado:

```
{
  "claim": "Tennis is not a sport.",
  "label": "REFUTES",
  "evidence": [
    "Tennis",
    "18",
    "Tennis is played by millions of recreational players and is also a popular worldwide spectator sport."
  ]
}
```

O sistema aprende a relação:

```
CLAIM + EVIDENCE -> LABEL
```

Semanticamente, no modelo utilizado no projeto:

```
SUPPORTS    -> TRUE
REFUTES     -> FALSE
NOT ENOUGH INFO -> UNCERTAIN
```

7. Como as evidências do dataset foram obtidas

Para afirmações classificadas originalmente como SUPPORTS ou REFUTES, o fever_gold_evidence utiliza as evidências consideradas corretas no FEVER.

Para NOT ENOUGH INFO, por definição não existe uma evidência capaz de provar ou refutar a afirmação. Para permitir o treinamento também nesses casos, os criadores recuperaram textos relacionados utilizando o sistema Papelo, empregado no FEVER 2018.

```
Claim + evidência relacionada, porém inconclusiva
↓
UNCERTAIN
```

Isso é importante para o nosso projeto porque ausência de comprovação não deve ser tratada automaticamente como falsidade.

8. Modelo base

O classificador foi construído a partir do xlm-roberta-base. O XLM-RoBERTa é um Transformer multilíngue pré-treinado em aproximadamente 2,5 TB de dados do CommonCrawl, abrangendo cerca de 100 idiomas.

A configuração do fact-checker possui:

- 12 camadas Transformer
- 768 dimensões ocultas
- 12 attention heads
- aproximadamente 270 milhões de parâmetros

Portanto, o modelo não foi treinado do zero para fact-checking. O processo foi:

```

Grande quantidade de textos
↓
Pré-treinamento XLM-RoBERTa
↓
XLM-RoBERTa Base
↓
Fine-tuning com FEVER
↓
XLM-RoBERTa Fact Checker

```

9. Treinamento específico do fact-checker

A versão atual, v2, foi treinada utilizando pares Claim + Evidence.

- Base model: xlm-roberta-base
- Fine-tuning: 1 época
- Learning rate: 5e-6
- Entrada: claim + evidence

Durante o treinamento, o modelo recebe exemplos no formato:

```
[claim] </s></s> [evidence]
```

junto com a classificação esperada. O treinamento ajusta os pesos para identificar TRUE, FALSE ou UNCERTAIN em novos pares de afirmação e evidência.

É importante separar a versão atual da versão antiga. A v1 utilizava essencialmente a claim, foi treinada por 3 épocas, com learning rate de 2e-5, batch size 32 e tamanho máximo de 256 tokens. Esses parâmetros pertencem à versão anterior, não à v2.

Para a v2, os parâmetros documentados são:

- Épocas: 1
- Learning rate: 5e-6
- Entrada: Claim + Evidence
- Dataset: copenlu/fever_gold_evidence
- Modelo base: xlm-roberta-base

O autor não documenta, no Model Card atual, parâmetros como batch size, optimizer, warmup ou weight decay da v2; por isso, esses valores não devem ser inventados no relatório.

10. Desempenho informado

Segundo o autor, a versão anterior, baseada apenas na claim, apresentou:

Macro F1: 0.655

Accuracy: 0.63

A versão atual, utilizando claim + evidence, apresentou:

Macro F1: 0.813

Accuracy: 0.79

Isso evidencia a importância de utilizar evidências na inferência, em vez de passar somente a afirmação.

11. Recuperação de evidências

Esta é uma das partes mais importantes para a implementação: o XLM-RoBERTa Fact Checker não pesquisa a internet sozinho. Ele apenas compara uma afirmação com uma evidência fornecida.

afirmação <-> evidência fornecida

Portanto, antes do classificador é necessário existir um sistema de recuperação de informações. A implementação descrita pelo autor utiliza:

- Embedding model: BAAI/bge-base-en-v1.5
- Busca vetorial: FAISS
- Base indexada: 56.946 trechos de evidências do FEVER

Fluxo aproximado:


```

Claim
↓
Transformação em embedding
↓
BGE
↓
Busca por similaridade
↓
FAISS
↓
Trechos mais relacionados
↓
XLM-RoBERTa Fact Checker
  
```

Sem uma etapa de recuperação de evidência, a versão atual perde justamente a informação para a qual foi ajustada.

12. Como utilizar no nosso projeto

O pipeline proposto para o critério Fatos Incontestáveis será:



Exemplo

Texto recebido:

A vacina X foi aprovada pela Anvisa em 2024.

Claim extraída:

```
{
  "claim": "A vacina X foi aprovada pela Anvisa em 2024."
}
```

Depois o sistema busca uma fonte relacionada, por exemplo:

Segundo o registro oficial da Anvisa, a vacina X recebeu autorização em 15 de março de 2024.

Entrada do classificador:

A vacina X foi aprovada pela Anvisa em 2024.

</s></s>

Segundo o registro oficial da Anvisa, a vacina X recebeu autorização em 15 de março de 2024.

Uma saída possível seria:

TRUE

13. Código básico de inferência

Uma implementação simplificada pode utilizar a biblioteca transformers:

```

import torch
from transformers import AutoTokenizer, AutoModelForSequenceClassification

MODEL_NAME = "Ashg2099/xlm-roberta-factchecker"

tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)
model = AutoModelForSequenceClassification.from_pretrained(MODEL_NAME)

claim = "A Segunda Guerra Mundial terminou em 1945."
evidence = "World War II ended in 1945 following the surrender of the Axis powers."

text = f'{claim} </s></s> {evidence}'

inputs = tokenizer(
    text,
    return_tensors="pt",
    truncation=True,
    max_length=256
)

with torch.no_grad():
    output = model(**inputs)

probabilities = torch.softmax(output.logits, dim=-1)[0]
predicted_id = probabilities.argmax().item()
label = model.config.id2label[predicted_id]

print(label)
print(probabilities)

```

A etapa de recuperação da evidência deve acontecer antes dessa inferência.

14. Adaptação necessária para nosso problema

O modelo disponível não resolve sozinho o processo completo de checagem de notícias. Precisaremos de pelo menos três componentes:

1. Extrator de claims - transforma a notícia em afirmações verificáveis.
2. Recuperador de evidências - encontra textos relevantes em fontes selecionadas.
3. XLM-RoBERTa Fact Checker - compara a afirmação com a evidência e classifica o resultado.

XLM-RoBERTa ≠ buscador de fatos

XLM-RoBERTa = classificador claim/evidence

15. Questão importante para notícias brasileiras

Embora o XLM-RoBERTa seja multilíngue, existe uma diferença entre o modelo base e os dados usados no fine-tuning. O XLM-RoBERTa foi pré-treinado em cerca de 100 idiomas, mas o `copenlu/fever_gold_evidence` usado no ajuste de fact-checking é um dataset em inglês.

Além disso, o recuperador indicado pelo autor, `bge-base-en-v1.5`, também é voltado para inglês. Por isso, não é seguro assumir que o desempenho reportado em inglês será reproduzido em notícias brasileiras.

Antes do uso definitivo, é recomendável criar um conjunto de teste em português, por exemplo:

100 afirmações verdadeiras
100 afirmações falsas
100 afirmações inconclusivas

com evidências brasileiras previamente verificadas. Em seguida, podemos medir:

Accuracy
Precision
Recall
F1-score
Matriz de confusão

16. Como transformar os resultados no critério “Fatos Incontestáveis”

Após verificar todas as afirmações da notícia, podemos consolidar os resultados:

```
{
  "claims_analisadas": 5,
  "true": 3,
  "false": 1,
  "uncertain": 1
}
```

E apresentar ao usuário:

Fatos sustentados: 3/5
Fatos contraditos: 1/5
Fatos sem evidência suficiente: 1/5

Isso é preferível a dizer que uma notícia é “60% verdadeira”, porque UNCERTAIN não significa falso e uma mesma notícia pode misturar fatos verdadeiros, falsos e não verificáveis.

17. Definição final do critério

Fatos Incontestáveis será o critério responsável por identificar as afirmações factuais presentes em uma notícia e verificar se essas afirmações são sustentadas, contraditas ou não podem ser determinadas a partir de evidências recuperadas de fontes externas.

Cada afirmação será analisada individualmente pelo modelo Ashg2099/xlm-roberta-factchecker, que utiliza XLM-RoBERTa e foi ajustado com dados do FEVER para classificação factual em três categorias: TRUE, FALSE e UNCERTAIN.

O modelo não será responsável pela obtenção das evidências. Portanto, ele será utilizado dentro de um pipeline que primeiro extrai afirmações verificáveis da notícia, recupera evidências relevantes e somente então executa a classificação.

A saída servirá para informar ao usuário quais afirmações possuem suporte documental, quais são contraditas pelas fontes consultadas e quais permanecem inconclusivas.

Resumo do modelo

Item	Informação
Modelo	Ashg2099/xlm-roberta-factchecker

Modelo base	xlm-roberta-base
Tarefa	Classificação factual
Entrada	Claim + Evidence
Formato	[claim] </s></s> [evidence]
Saída	TRUE / FALSE / UNCERTAIN
Dataset	copenlu/fever_gold_evidence
Dataset base	FEVER
Fine-tuning v2	1 época
Learning rate	5e-6
Tokens	até 256 na configuração publicada do tokenizer
Retriever indicado	BAAI/bge-base-en-v1.5
Índice indicado	FAISS
Evidências indexadas	56.946
Macro F1 informado	0.813
Accuracy informada	0.79
Principal limitação	Necessita evidência externa
Idioma do dataset de fine-tuning	Inglês
Uso pretendido no projeto	Classificar cada fato individualmente

Referências principais

- **Modelo no Hugging Face:** <https://huggingface.co/Ashg2099/xlm-roberta-factchecker>
- **Configuração do modelo:** <https://huggingface.co/Ashg2099/xlm-roberta-factchecker/blob/main/config.json>
- **Dataset fever_gold_evidence:** https://huggingface.co/datasets/copenlu/fever_gold_evidence
- **FEVER Dataset:** <https://fever.ai/dataset/fever.html>
- **XLM-RoBERTa Base:** <https://huggingface.co/FacebookAI/xlm-roberta-base>